

# **Avaliação de um RAG Jurídico-Saúde-IA Responsável em Português**

Recuperação, geração e viabilidade de embeddings abertos

## Sumário

---

|                                                                   |           |
|-------------------------------------------------------------------|-----------|
| <b>Sumário</b>                                                    | <b>2</b>  |
| <b>1. A ferramenta</b>                                            | <b>3</b>  |
| <b>2. Arquitetura e tecnologias</b>                               | <b>3</b>  |
| 2.1 Fluxo, da ingestão à resposta                                 | 3         |
| 2.2 Modelos e infraestrutura                                      | 3         |
| 2.3 O acervo                                                      | 4         |
| <b>3. Como o conjunto de avaliação é construído</b>               | <b>4</b>  |
| 3.1 Gabarito ancorado no corpus                                   | 4         |
| 3.2 Por que não usamos um dataset público                         | 4         |
| 3.3 Por que não há descasamento de IDs                            | 5         |
| 3.4 Exemplos (estilo da persona)                                  | 5         |
| 3.5 Prompt de perfilamento para auxiliar na geração das perguntas | 6         |
| <b>4. Visão geral da avaliação</b>                                | <b>7</b>  |
| <b>5. Pré-requisitos (antes de rodar)</b>                         | <b>8</b>  |
| <b>6. Etapa 1 — Conjunto de avaliação (gold set)</b>              | <b>8</b>  |
| <b>7. Etapa 2 — Recuperação (eval/retrieval_eval/)</b>            | <b>9</b>  |
| <b>8. Etapa 3 — Geração e juízes (eval/generation_eval/)</b>      | <b>9</b>  |
| 8.1 Os dois juízes e os critérios                                 | 10        |
| 8.2 Com RAG vs. sem RAG — o valor da ferramenta                   | 10        |
| <b>9. Etapa 4 — Concordância e relatório</b>                      | <b>11</b> |
| <b>10. Ordem de execução (resumo)</b>                             | <b>11</b> |
| <b>11. Limitações</b>                                             | <b>11</b> |
| <b>12. Glossário</b>                                              | <b>11</b> |

## 1. A ferramenta

A ferramenta é um **chatbot de RAG** (Retrieval-Augmented Generation) que responde, em linguagem acessível e **sempre citando as fontes**, a dúvidas sobre legislação, normas e boas práticas de **saúde e governança de IA**, a partir de um acervo curado de documentos oficiais brasileiros e internacionais.

### Para quem

- Médicos e profissionais de saúde que conduzem projetos de IA responsável.
- Auditores de IA responsável. Nenhum dos dois é jurista — a ferramenta traduz a norma em orientação prática.
- Desenvolvedores de sistemas que utilizam Inteligência Artificial

**Caso de uso.** O usuário pergunta em português, no dia a dia — por exemplo, “por quanto tempo preciso guardar o prontuário de uma teleconsulta?”. O chatbot recupera os trechos relevantes, responde de forma fundamentada e lista as fontes; quando a resposta não está no acervo, RECUSA em vez de inventar (essencial num domínio de alto risco).

**Bílingue por necessidade.** As dúvidas são em português, mas boa parte da referência técnica é internacional e está em inglês (GDPR, OMS, FDA, NIST, OCDE). A ferramenta recupera esse conteúdo em inglês e responde em português.

## 2. Arquitetura e tecnologias

### 2.1 Fluxo, da ingestão à resposta

| Etapa        | Como                                                                                                             | Papel                           |
|--------------|------------------------------------------------------------------------------------------------------------------|---------------------------------|
| Ingestão     | PDFs oficiais convertidos em texto                                                                               | Monta o acervo                  |
| Fragmentação | trechos de ~1.200 caracteres (sobreposição 200); cada um recebe um ID único (ex.: resolucão_2314_CFM_2022_p3_c0) | Unidade indexada e recuperada   |
| Embedding    | um vetor por trecho, armazenado no banco vetorial Qdrant                                                         | Habilita a busca semântica      |
| Recuperação  | BM25 (léxico) + denso (semântico) + fusão (RRF). Limiar de 0,60 e o top-k=5                                      | Encontra os trechos certos      |
| Geração      | Qwen3.6-27B, temperatura 0, prompt que EXIGE citar as fontes e proíbe inventar                                   | Escreve a resposta fundamentada |
| Orquestração | agente em LangGraph                                                                                              | Encadeia recuperar → responder  |

### 2.2 Modelos e infraestrutura

| Papel         | Modelo      | Onde roda |
|---------------|-------------|-----------|
| Gerador (RAG) | Qwen3.6-27B | Groq      |

| Papel                    | Modelo                                    | Onde roda            |
|--------------------------|-------------------------------------------|----------------------|
| Embedding — proprietário | gemini-embedding-001 (3072d, multilíngue) | API Google + Qdrant  |
| Embedding — aberto       | BGE-m3 (~560M, 1024d, multilíngue)        | Auto-hospedado (CPU) |
| Juízes (avaliação)       | Llama-3.3-70B + gpt-oss-120B              | Groq                 |
| Gerador do gabarito      | LLM independente (não avaliada)           | em sessão / API      |

## 2.3 O acervo

**63 documentos** oficiais (~**5.791 trechos**), **bilíngue** (≈46% em português, ≈54% em inglês) e cross-jurisdicional:

- **Brasil:** Resoluções CFM (telemedicina 2.314/2022, ética médica 2.217/2018, ANPD), LGPD, PL 2338/2023, Estratégia (MCTI) e Plano Brasileiro de IA, Lei de Pesquisa Clínica 14.874/2024, entre outros.
- **Internacional:** GDPR e European Health Data Space (UE), OMS, FDA, NIST, UNESCO, OCDE, IMDRF, normas ISO.

## 3. Como o conjunto de avaliação é construído

Para medir **recuperação** precisamos de **qrels** — julgamentos de relevância que apontem para os IDs dos **ossos próprios chunks**. Por isso o conjunto é **gerado a partir da nossa base**, e não de um dataset externo.

### 3.1 Gabarito ancorado no corpus

**Como funciona.** Uma LLM independente — o Claude (neste artigo) ou outra LLM que NÃO seja avaliada — lê um chunk nosso e cria uma pergunta a partir dele. (Não usamos o Gemini para gerar o gabarito, pois ele é avaliado como embedding e poderá ser testado como gerador depois — isso evita viés.) Como a pergunta nasceu daquele chunk, sabemos, por construção, que ele é o documento relevante — o qrel é gerado automaticamente (chunk-fonte = grau 2; vizinhos = grau 1). O mesmo gabarito serve às duas etapas: os qrels avaliam a recuperação e as respostas-referência avaliam a geração.

### 3.2 Por que não usamos um dataset público

Avaliamos a possibilidade de usar um benchmark público e levantamos os candidatos mais próximos em português. Nenhum deles avalia aquilo que precisamos avaliar:

| Candidato levantado     | Por que não serve aqui                                                                                                                                                          |
|-------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| BR-TaxQA-R (unicamp-dl) | QA jurídico com referências, mas do domínio TRIBUTÁRIO — não cobre saúde nem governança de IA.                                                                                  |
| legalbench.br (celsowm) | Benchmark jurídico brasileiro de tarefas variadas; jurídico geral, sem o recorte sanitário/IA e sem ligação com o nosso acervo.                                                 |
| JurisTCU                | Recuperação jurídica COM julgamentos de relevância — porém sobre o corpus próprio (jurisprudência do TCU). Os qrels apontam para os documentos dele, não para os nossos chunks. |
| HealthQA-BR (Larxel)    | 5.632 questões de provas de licenciamento/residência: mede CONHECIMENTO CLÍNICO em múltipla escolha, não geração fundamentada em documentos normativos recuperados.             |

| Candidato levantado                          | Por que não serve aqui                                                                       |
|----------------------------------------------|----------------------------------------------------------------------------------------------|
| lavita/medical-qa-datasets;<br>bigbio/med_qa | QA médico majoritariamente em inglês e em múltipla escolha — língua e formato incompatíveis. |

Duas incompatibilidades são de fundo. (1) DOMÍNIO: nenhum cobre a interseção jurídico-saúde + governança de IA — são tributários, jurídicos gerais ou de conhecimento clínico. (2) TAREFA: os de múltipla escolha medem o conhecimento interno do modelo, não a fidelidade de uma resposta gerada a partir de um contexto recuperado do NOSSO acervo; e os de recuperação trazem qrels contra os próprios corpora, não contra os nossos chunks. Usá-los mediria outra coisa e daria uma falsa sensação de validade externa.

A ausência de um benchmark adequado a este domínio é, aliás, uma das lacunas que motivam este trabalho (Seção 2) — usar um benchmark de encaixe ruim contradiria o próprio argumento. Construir ou adotar um benchmark público PT-BR de RAG jurídico-saúde fica como trabalho futuro.

### 3.3 Por que não há descasamento de IDs

O qrel não é “adivinhado”: é conhecido porque a pergunta foi feita a partir do chunk. O ID é o mesmo do nosso documents.jsonl e do Qdrant. Exemplo de registro:

```
{ "qid": "q0001",
  "question": "No acompanhamento de doenças crônicas por teleconsulta, é obrigatório algum atendimento presencial?",
  "reference_answer": "Sim. A Resolução CFM nº 2.314/2022 exige, no acompanhamento de doenças crônicas ou que demandem acompanhamento por longo tempo, consulta presencial com o médico assistente em intervalos não superiores a 180 dias.",
  "question_type": "factual", "source_lang": "pt",
  "difficulty": "easy", "theme": "Telemedicina",
  "source_docs": ["resolucao_2314_CFM_2022.pdf"],
  "qrels": { "resolucao_2314_CFM_2022_p4_c2": 2,
             "resolucao_2314_CFM_2022_p3_c0": 1,
             "resolucao_2314_CFM_2022_p3_c1": 1 } }
```

*Os qrels estão abreviados — o registro real tem 9 (um grau 2 e oito vizinhos grau 1).*

Tipos de pergunta (robustez): factual (1 chunk), multi-hop (2+ chunks do mesmo documento), comparativa (documentos distintos) e fora-de-escopo/inanswerable (qrels vazio — testa recusa). Em multi-hop, os chunks de um mesmo documento são enviados ao LLM em ordem (página e bloco), pois a ordem dos trechos no contexto afeta o aproveitamento por modelos de longo contexto [3] — ordem essa codificada no próprio ID, no formato nomeDocumento\_p{página}\_c{bloco}. 50 das 100 perguntas são validadas por curadoria humana.

Cada tipo testa uma capacidade diferente, e o **qrels** (quais chunks são relevantes) muda conforme o tipo:

| Tipo           | O que exige                     | qrels                     | Exemplo no seu domínio                                                                    |
|----------------|---------------------------------|---------------------------|-------------------------------------------------------------------------------------------|
| Factual        | 1 chunk responde                | chunk-fonte=2, vizinhos=1 | "Qual o prazo de guarda do prontuário em telemedicina?" (1 trecho da CFM 2.314/2022)      |
| Multi-hop      | combinar 2+ chunks do mesmo doc | os 2 chunks=2             | resposta que precisa da <i>definição</i> (p2) e da <i>exceção</i> (p5) da mesma resolução |
| Comparativa    | relacionar 2 docs diferentes    | 1 chunk de cada doc=2     | "Como a CFM 2.314 e a LGPD tratam o sigilo de dados em telemedicina?"                     |
| Fora-de-escopo | resposta não está no corpus     | { } (vazio)               | "Qual a lei de telemedicina em Portugal?" → deve recusar                                  |

- Multi-hop existe para testar se a busca traz os dois pedaços necessários e se o gerador sintetiza entre eles — é mais difícil que factual.
- Fora-de-escopo tem qrels vazio de propósito: não entra na recuperação (não há chunk certo) e serve só para medir recusa na geração (a resposta correta é "não encontrei informações suficientes...").

As perguntas são redigidas para o PÚBLICO-ALVO do RAG — médicos com projetos de IA responsável e auditores de IA responsável e desenvolvedores de sistemas de IA na área da saúde, que não são juristas — em linguagem acessível e evitando jargão jurídico, refletindo dúvidas reais sobre conformidade, ética e governança. Geramos 25 perguntas de cada tipo, 100 no total — 75 respondíveis e 25 fora de escopo.

### 3.4 Exemplos (estilo da persona)

Exemplos ancorados nos documentos já indexados (CFM nº 2.314/2022 e PL nº 2338/2023):

| Tipo           | Pergunta → resposta-referência                                                                                                                                                                                                                   | qrels (chunks)                                 |
|----------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------|
| Factual        | Na telemedicina, os dados e imagens do paciente no prontuário precisam ser guardados seguindo alguma regra? → Sim; a Resolução CFM 2.314/2022 (Art. 3º) determina preservá-los conforme as normas de guarda do CFM e a legislação.               | 2314_2022_p3_c1 = 2;<br>p3_c0 = 1              |
| Multi-hop      | Que cuidados com os dados o médico deve ter ao RECEBER as informações e ao GUARDAR o prontuário na telemedicina? → Avaliar se as informações são qualificadas e seguras ao receber; preservar os dados/imagens do prontuário conforme as normas. | 2314_2022_p2_c0 = 2;<br>p3_c1 = 2              |
| Comparativa    | Como a resolução de telemedicina (CFM) e o PL 2338/2023 tratam a proteção de dados pessoais? → A CFM considera a LGPD na telemedicina; o PL 2338 coloca privacidade e proteção de dados entre seus fundamentos e remete à LGPD.                  | 2314_2022_p2_c1 = 2;<br>PL-2338-2023_p2_c1 = 2 |
| Fora-de-escopo | Quantos processos por erro médico envolvendo IA foram julgados no Brasil em 2024? → "Não encontrei informações suficientes nas fontes recuperadas..." (deve recusar).                                                                            | { } (vazio)                                    |

### 3.5 Prompt de perfilamento para auxiliar na geração das perguntas

Foi utilizado o modelo claude para a geração das 100 perguntas

PAPEL E PÚBLICO-ALVO

Você é especialista em direito da saúde e governança de IA no Brasil e está construindo um conjunto de avaliação (gold set) para um sistema de RAG.

O PÚBLICO que usa esse RAG são: (a) médicos que conduzem projetos de IA responsável e (b) auditores de IA responsável. Eles NÃO são juristas e têm pouca familiaridade com jargão jurídico. Portanto, as perguntas devem:

- soar como dúvidas REAIS desses perfis (conformidade, ética, governança, proteção de dados/LGPD, risco, responsabilidade, transparência — aplicados à prática clínica e à auditoria de IA);
- usar linguagem ACESSÍVEL; evitar jargão jurídico. Quando um termo técnico for inevitável, formule de modo compreensível para um não-jurista;
- focar em "o que preciso saber/fazer para estar em conformidade ou auditar", não em tecnicismos de doutrina jurídica.

#### TAREFA

A partir dos TRECHOS fornecidos, gere 100 perguntas com gabarito, distribuídas em 4 tipos:

1. **factual** — respondível por UM único trecho.
2. **multi\_hop** — exige COMBINAR 2+ trechos DO MESMO documento (nenhum sozinho responde). Considere os trechos em ORDEM de documento (página, bloco), do menor para o maior.
3. **comparative** — relaciona/compara DOIS documentos DIFERENTES sobre um ponto comum.
4. **unanswerable** — plausível para a persona, mas SEM resposta nos trechos. A resposta-referência deve ser EXATAMENTE:  
"Não encontrei informações suficientes nas fontes recuperadas para responder com segurança."

#### REGRAS

- Perguntas dos tipos 1–3 devem ser respondíveis SOMENTE pelos trechos citados.
- NUNCA use meta-referências ("segundo o texto", "no trecho acima"); a pergunta deve fazer sentido sozinha.
- A resposta-referência deve ser concisa e fiel aos trechos.
- Em cada pergunta respondível, "qrels" lista os chunk\_ids usados: grau 2 para o(s) trecho(s)-fonte (e grau 1 para vizinhos do mesmo documento, se fizer sentido).
- Em unanswerable, "qrels" é {} (vazio).
- Responda em português do Brasil e SOMENTE com JSON válido.

#### FORMATO DE SAÍDA (uma lista JSON)

```
[
  {
    "question": "...",
    "reference_answer": "...",
    "question_type": "factual | multi_hop | comparative | unanswerable",
    "difficulty": "easy | medium | hard",
    "qrels": { "<chunk_id>": 2 },
    "source_docs": ["<arquivo.pdf>"]
  }
]
```

#### TRECHOS (cada um: ID | DOCUMENTO | TEXTO)

{TRECHOS}

- o caminho automatizado (01\_build\_golden.py): sim, é automático. A orquestração lê o documents.jsonl, e para cada chunk (ou par de chunks) injeta o texto e os IDs sozinha na chamada do LLM. Você não mexe em {TRECHOS}; a persona está no SYS e as cotas vêm da config.

- O {TRECHOS} do prompt é para o caminho MANUAL/em-sessão (colar num LLM). É a versão "holística" (todos os trechos de uma vez). O código faz incrementalmente, por chunk/par.

## 4. Visão geral da avaliação

A avaliação valida a ferramenta em duas dimensões — RECUPERAÇÃO (acha a norma certa?) e GERAÇÃO (a resposta é fiel, citada e segura?) — mais a comparação COM vs. SEM RAG (o valor de fundamentar as respostas no acervo). Tudo é ancorado num gold set construído do próprio acervo.

**Pipeline modular.** Cada etapa é uma pasta/script; cada cenário grava seu próprio CSV, que alimenta a etapa seguinte (sem recuperar nada de novo). Mapa geral:

| Etapa                        | Pasta / script                                              | O que produz                                               |
|------------------------------|-------------------------------------------------------------|------------------------------------------------------------|
| 1 · Gabarito                 | eval/tools/build_gold_manual.py                             | golden_qa.jsonl (100 perguntas + qrels)                    |
| 2 · Recuperação              | eval/retrieval_eval/                                        | scenario_<sist>.csv + rankings + métricas                  |
| 3 · Geração                  | eval/generation_eval/                                       | judged_<tag>.jsonl + scenario_<tag>.csv (notas dos juízes) |
| 4 · Concordância + relatório | eval/04_agreement.py · eval/05_report.py                    | agreement.csv · report.md / report.xlsx                    |
| Planilhas                    | eval/tools/export_retrieval_xlsx.py · export_judged_xlsx.py | recuperacao.xlsx · respostas_julgadas.xlsx                 |

## 5. Pré-requisitos (antes de rodar)

- **Ambiente Python:** pip install -r eval/requirements-eval.txt
- **Chaves (arquivo .env na raiz):** GROQ\_API\_KEY (gerador + juízes), GEMINI\_API\_KEY (embedding proprietário), QDRANT\_URL e QDRANT\_API\_KEY (busca densa Gemini).
- **Qdrant indexado:** o denso-Gemini consulta a coleção do Qdrant de produção — garanta que o corpus atual está indexado lá.
- **Windows:** rode sempre com PYTHONUTF8=1 (evita erro de acentuação no console).

**Configuração central.** Tudo é dirigido por eval/config.yaml — modelos, caminhos, profundidade da busca (top\_k), critérios dos juízes, seed. Altere lá e re-rote; nenhum parâmetro fica espalhado no código.

## 6. Etapa 1 — Conjunto de avaliação (gold set)

Uma LLM independente (que NÃO é avaliada) leu trechos reais do acervo e escreveu perguntas. Como cada pergunta nasce de um trecho, sabemos qual é o documento relevante: os **qrels** apontam para os IDs dos NOSSOS trechos, sem risco de descasamento. São **100 perguntas — 25 de cada tipo**, extraídas de 13 documentos centrais do acervo:

| Tipo    | O que testa               |
|---------|---------------------------|
| Factual | respondível por UM trecho |

| Tipo           | O que testa                                                   |
|----------------|---------------------------------------------------------------|
| Multi-hop      | exige COMBINAR 2+ trechos do mesmo documento                  |
| Comparativa    | relaciona DOIS documentos/jurisdições sobre um ponto em comum |
| Fora-de-escopo | sem resposta no acervo — testa a RECUSA correta (qrels vazio) |

**Graus de relevância (graded relevance).** Cada qrel tem um grau: 2 para o chunk-fonte (de onde a pergunta nasceu), 1 para os vizinhos ( $\pm 1$  página do mesmo documento) e 0 para o não relevante. O nDCG usa ganho exponencial ( $2^{\text{grau}} - 1$ ) — o chunk-fonte vale ganho 3 e um vizinho, ganho 1 —, recompensando trazer o trecho certo ao topo.

Arquivos gerados (em eval/data/):

| Arquivo                 | Conteúdo                                                                   |
|-------------------------|----------------------------------------------------------------------------|
| golden_qa.jsonl         | as 100 perguntas: pergunta, resposta-referência, tipo, qrels, língua-fonte |
| queries.csv · qrels.csv | derivados (75 respondíveis) usados pelas métricas de recuperação           |

**Como (re)gerar.** As perguntas são autorais e ficam em eval/tools/build\_gold\_manual.py. Rodar valida cada chunk\_id contra o corpus e ABORTA se algum for inválido:

```
python eval/tools/build_gold_manual.py
```

Curadoria: 50 das 100 perguntas são validadas por curadoria humana antes de divulgar resultados.

## 7. Etapa 2 — Recuperação (eval/retrieval\_eval/)

Um script por cenário; cada um busca o top-100 no acervo inteiro e grava seu CSV. A fusão (C) usa os vencedores de A e B, então roda depois deles.

| Cenário (script)           | O que faz                                                                                                                                    |
|----------------------------|----------------------------------------------------------------------------------------------------------------------------------------------|
| scenario_A_bm25.py         | BM25 léxico. Gera DUAS variantes: A_bm25 (consulta PT) e A_bm25_mt (consulta traduzida PT→EN, CLIR — para alcançar os documentos em inglês). |
| scenario_B_dense_gemini.py | Busca densa com o embedding Gemini (via Qdrant).                                                                                             |
| scenario_B_dense_bge.py    | Busca densa, multi-vetor e híbrido com o BGE-m3 (aberto; roda em CPU, cache local).                                                          |
| scenario_C_fusion.py       | Fusão RRF do MELHOR BM25 + MELHOR denso (escolhidos por nDCG@5). Rodar DEPOIS de A e B.                                                      |

**Como rodar — um cenário isolado, ou todos na ordem:**

```
python eval/retrieval_eval/scenario_A_bm25.py
```

```
python eval/retrieval_eval/run_all.py # A, B(gemini), B(bge), C + artefatos combinados
```

Saídas (em eval/results/retrieval/):

| Arquivo                    | Conteúdo                                                                                                                                        |
|----------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------|
| scenario_<sist>.csv        | 1 linha por consulta: os 5 trechos recuperados — para cada um o id, o grau de qrel e o TEXTO completo — e as métricas; a última linha é a MÉDIA |
| rankings/<sist>.json       | ranking completo (top-100) — consumido pela fusão e pela geração                                                                                |
| metrics.csv · metrics.json | médias de todos os sistemas (geradas pelo run_all)                                                                                              |

**Métricas:** nDCG@5 (principal) e @10, Precision@5, Recall@5/@10/@100, F1@5, MRR@10, MAP.

**Cache — não regenera a cada execução.** O índice BM25 (bm25\_tokens\_\*.pkl), os embeddings densos do BGE (dense\_\*.npz) e as traduções da consulta (query\_translations.json) ficam em eval/results/indexes/. A 1ª execução gera; as próximas carregam.

**Planilha consolidada:**

```
python eval/tools/export_retrieval_xlsx.py # → recuperacao.xlsx
```

Abas: legenda · resumo (todos os sistemas) · uma por sistema (métricas por consulta) · ablação\_bm25 (efeito da tradução por língua).

## 8. Etapa 3 — Geração e juízes (eval/generation\_eval/)

O RAG (Qwen3.6-27B) gera a resposta a partir do contexto recuperado (top-5), e dois juízes-LLM independentes pontuam. Requer a recuperação já rodada (usa os rankings). Um script por cenário:

| Cenário (script)     | Contexto que alimenta o Qwen                 | ICL            |
|----------------------|----------------------------------------------|----------------|
| scenario_A_bm25.py   | recuperação do BM25                          | sem e com      |
| scenario_B_dense.py  | recuperação do denso implantado              | sem e com      |
| scenario_C_fusion.py | recuperação da fusão de deploy               | sem e com      |
| scenario_no_rag.py   | NENHUM — Qwen sozinho (conhecimento próprio) | condição única |

**ICL (in-context learning):** exemplos few-shot no prompt. A comparação com/sem ICL é feita SÓ nos cenários com RAG; o sem-RAG é uma condição única (a LLM pura), para medir o valor da ferramenta.

**Como rodar:**

```
python eval/generation_eval/run_all.py # todos + os 2 juízes
python eval/generation_eval/scenario_C_fusion.py --limit 30 # um cenário, com amostra
```

Saídas (em eval/results/generation/); tag = <cenário>\_icl0/1 ou no\_rag:

| Arquivo            | Conteúdo                                                                                          |
|--------------------|---------------------------------------------------------------------------------------------------|
| judged_<tag>.jsonl | bruto: resposta + notas e justificativas de cada juiz                                             |
| scenario_<tag>.csv | organizado: pergunta, resposta, contexto, referência e a nota de CADA juiz por critério + a média |

### 8.1 Os dois juízes e os critérios

Juízes independentes (≠ gerador): Llama-3.3-70B e gpt-oss-120B. Cada um pontua de 1 a 5, com justificativa:

| Critério   | O que mede                                                       |
|------------|------------------------------------------------------------------|
| Fidelidade | a resposta é sustentada pelo contexto recuperado (não extrapola) |
| Correção   | concorda com a resposta-referência do gabarito                   |
| Relevância | responde à pergunta                                              |

| Critério    | O que mede                                                                              |
|-------------|-----------------------------------------------------------------------------------------|
| Compleitude | cobre os pontos essenciais                                                              |
| Citação     | a seção “Fontes utilizadas” está presente e correta                                     |
| Alucinação  | severidade de fatos, leis ou números inventados (5 = nenhuma) → vira taxa de alucinação |
| Recusa      | recusou corretamente quando a pergunta estava fora do escopo                            |

## 8.2 Com RAG vs. sem RAG — o valor da ferramenta

A comparação decisiva: respostas fundamentadas no acervo são melhores do que apenas perguntar ao modelo? O cenário no\_rag (Qwen sozinho) é o baseline, nas mesmas perguntas e com os mesmos juízes.

| O que se compara | Por que o RAG deve superar a LLM sozinha                                                                              |
|------------------|-----------------------------------------------------------------------------------------------------------------------|
| Correção         | o modelo sozinho dificilmente acerta a norma específica (ex.: o prazo de 180 dias da CFM); o RAG traz o trecho exato. |
| Alucinação       | sem o acervo, o modelo tende a inventar leis, artigos e números; o contexto ancora a resposta.                        |
| Citação          | só o RAG tem fontes a apontar; o modelo sozinho não tem o que citar, ou fabrica citações.                             |
| Recusa           | nas perguntas fora de escopo, o RAG recusa; o modelo sozinho tende a responder mesmo assim.                           |

## 9. Etapa 4 — Concordância e relatório

- **Concordância entre juízes:** python eval/04\_agreement.py —  $\kappa$  de Cohen ponderado. Antes de confiar nas notas, mede-se se os dois juízes concordam o suficiente para servirem de instrumento.
- **Relatório consolidado:** python eval/05\_report.py — comparações e significância (fusão vs. melhor isolado, etc.) em report.md / report.xlsx.
- **Planilha das respostas:** python eval/tools/export\_judged\_xlsx.py → respostas\_julgadas.xlsx (abas: respostas, justificativas, resumo), reunindo TODOS os cenários, inclusive o sem-RAG.

**Significância (enxuta).** Médias por sistema + um teste pareado no confronto principal da recuperação, e a concordância  $\kappa$ . Análises mais pesadas (não-inferioridade aberto-vs-proprietário, estratos de idioma) ficam como material suplementar no repositório.

## 10. Ordem de execução (resumo)

Sequência completa (no Windows, prefixe cada comando com PYTHONUTF8=1):

```
python eval/tools/build_gold_manual.py      # 1. gabarito (100 perguntas)
python eval/retrieval_eval/run_all.py      # 2. recuperação (A, B, B, C)
python eval/generation_eval/run_all.py     # 3. geração + juízes
python eval/04_agreement.py                # 4. concordância entre juízes
python eval/05_report.py                   # 5. relatório consolidado
python eval/tools/export_retrieval_xlsx.py # planilha da recuperação
python eval/tools/export_judged_xlsx.py    # planilha das respostas
```

**Custo e piloto.** A recuperação é local e rápida (com cache). A geração é o passo caro: são 7 configurações (A/B/C × ICL, mais o sem-RAG) × ~75–100 perguntas × 2 juízes, tudo via API (Groq). Rode primeiro um piloto com --limit 20–30 para validar antes do run completo.

## 11. Limitações

- **Gabarito sintético:** as perguntas são escritas por LLM; mitigado por curadoria humana de amostra e por qrels corretos por construção.
- **Juiz-LLM:** Dois juízes independentes, ambos diferentes do gerador. A concordância medida é fraca: apenas 1 dos 7 critérios atinge o limiar de  $\kappa$  ponderado  $\geq 0,6$  fixado a priori.

| Critério    | $\kappa$ ponderado | Concordância bruta |
|-------------|--------------------|--------------------|
| Relevância  | 0,643              | 64%                |
| Compleitude | 0,578              | 40%                |
| Correção    | 0,550              | 57%                |
| Recusa      | 0,541              | 89%                |
| Fidelidade  | 0,348              | 54%                |
| Alucinação  | 0,272              | 74%                |
| Citação     | 0,089              | 55%                |

A causa é um viés sistemático de severidade: um dos juízes é mais brando nos sete critérios, com diferença média de 0,87 ponto em citação. Note que  $\kappa$  e concordância bruta divergem bastante (alucinação:  $\kappa$  0,27 com 74% de acordo) — efeito de teto, com quase todas as notas concentradas em 5.

Mitigação. As conclusões centrais não dependem das médias das notas. A acurácia de recusa é medida por detecção da frase de recusa, sem juiz. A taxa de alucinação conta apenas as respostas que ambos os juízes marcaram como graves — contagem por interseção, não por união — e a queda se reproduz sob cada juiz isoladamente: de 24 para 1 (juiz 1) e de 78 para 7 (juiz 2) respostas em 100. Notas de critérios abaixo do limiar devem ser lidas com ressalva.

- **Cobertura:** o gabarito cobre 13 dos 63 documentos (os mais centrais para a persona); ampliar a cobertura é trabalho futuro.
- **Escopo:** acervo e domínio específicos — os resultados valem para este contexto.

## 12. Glossário

| Termo          | Significado                                                                   |
|----------------|-------------------------------------------------------------------------------|
| RAG            | geração de respostas fundamentada em documentos recuperados                   |
| Chunk / trecho | unidade de documento indexada e recuperada                                    |
| Embedding      | vetor que representa o significado de um texto (busca semântica)              |
| BM25 / CLIR    | busca por palavras-chave / recuperação com a consulta traduzida entre idiomas |

| <b>Termo</b>      | <b>Significado</b>                                                            |
|-------------------|-------------------------------------------------------------------------------|
| RRF               | Reciprocal Rank Fusion — combina rankings de sistemas diferentes              |
| qrels             | julgamentos de relevância: quais trechos respondem cada pergunta (grau 2/1/0) |
| nDCG / MRR        | qualidade do ranking (acertos no topo) / posição do primeiro relevante        |
| ICL               | In-Context Learning: exemplos few-shot no prompt do gerador                   |
| LLM como juiz     | usar um modelo de linguagem para avaliar automaticamente as respostas         |
| $\kappa$ de Cohen | concordância entre avaliadores, corrigida pelo acaso                          |